Danilo Dell'Orco Jacopo Fabi Michele Salvatori


SABD — Progetto 1

ANALISI DEL DATASET DEI TAXI DI NYC

Introduzione


- L'obiettivo del progetto è quello di analizzare i dati forniti dal Taxi and Limousine Commission (TLC) riguardo le corse effettuate dai taxi, in particolare utilizzando il dataset "TLC Trip Record Data" fornito in formato parquet.
- Si applica tramite NiFi una fase di pre-processamento e caricamento del dataset su HDFS, utilizzato come layer di storage.
- L'analisi e l'esecuzione delle query avviene tramite Spark, sia sfruttando l'RDD API di più basso livello sia tramite l'astrazione offerta da SparkSQL.
- I risultati delle query vengono inseriti su MongoDB e salvati anche in formato CSV su HDFS.
- In aggiunta, i risultati ottenuti dall'esecuzione delle diverse query vengono resi visualizzabili tramite una dashboard offerta dal framework Grafana.

Architettura



Architettura (2)


- Il numero di nodi workers Spark è stato scelto testando il tempo di risposta al variare del loro numero in esecuzione.
- La valutazione è basata sulla query 2 essendo la più complessa.
- Sono state effettuate cinque iterazioni per ogni configurazione del numero di workers.
- Consideriamo il valore della media e della varianza per identificare la configurazione ideale.



O2 Exec ——Variance

NiFi

• Il flusso di **NiFi** è stato progettato per rimuovere dal dataset eventuali dati corrotti e colonne inutili non necessarie nella fase di processamento tramite Spark.



NiFi (2)

Il dataset viene filtrato nel processore QueryRecord:

- Vengono eliminate le righe che presentano campi d'interesse con valori negativi.
- Vengono eliminate le righe che presentano come timestamp di fine corsa un valore che non rientra nei tre mesi in analisi.
- Vengono selezionate solamente le colonne necessarie per rispondere alle diverse query.

```
SELECT tpep_pickup_datetime, tpep_dropoff_datetime, PULocationID, DOLocationID,
payment_type, fare_amount, tip_amount, tolls_amount, total_amount, passenger_count
FROM FLOWFILE
WHERE (payment_type>0 AND tip_amount>=0 AND tolls_amount>=0 AND total_amount>=0
        AND fare_amount>=0 AND passenger_count>=0
        AND (tpep_dropoff_datetime BETWEEN '2021-12-01 00:00:01' AND '2022-02-28 23:59:59'))
```

NiFi (3)

Il processore MergeRecord viene utilizzato per unire più flowfiles in un singolo flowfile:

- L'obiettivo è scrivere su HDFS un singolo file parquet che rappresenta il dataset finale.
- Reso bloccante finché non sono stati uniti tutti i records in un singolo flowfile di output.
- Il numero massimo e minimo di records è impostato al numero totale di righe del dataset in output alla fase di filtraggio così da produrre una singola bin.

Property Value					
Record Reader	9	ParquetReader	→		
Record Writer	9	ParquetRecordSetWriter	→		
Merge Strategy	9	Bin-Packing Algorithm			
Correlation Attribute Name	9	No value set			
Attribute Strategy	9	Keep Only Common Attributes			
Minimum Number of Records	9	8336885			
Maximum Number of Records	9	8336885			

NiFi (4)

Il processore InvokeHTTP effettua una POST all'indirizzo della macchina che ospita la rete dei vari containers:

- Lo script seguente avvia HDFS e ne effettua il format, lancia il flusso di NiFi e si mette in ascolto sulla porta 5555.
- Al termine del flusso il server riceverà la POST dal processore.
- Si procedere ripristinando il flusso per una nuova esecuzione stoppandolo tramite le REST API offerte da Apache.


```
from http.server import BaseHTTPRequestHandler, HTTPServer
import subprocess
import urllib.request
import signal
import os
class handler(BaseHTTPRequestHandler):
    def do POST(self):
        # stop nifi flow
       subprocess.call(['sh', './stop-nifi-flow.sh'])
       os.kill(os.getpid(), signal.SIGTERM)
with HTTPServer(('172.17.0.1', 5555), handler) as server:
    subprocess.call(['sh', './start-hdfs.sh'])
   message = 0
   while (message != 200):
            message = urllib.request.urlopen("http://localhost:8090/nifi")
                      .getcode()
            print("Nifi Web UI is up and running!")
            print(message)
        except:
            print("Nifi not running...")
   subprocess.call(['sh', './start-nifi-flow.sh'])
   server.serve_forever()
```

Query 1

«Per ogni mese solare, calcolare la percentuale media dell'importo della mancia rispetto al costo della corsa esclusi i pedaggi.


Calcolare il costo della corsa come differenza tra l'importo totale (Total amount) e l'importo dei pedaggi (Tolls amount) ed includere soltanto i pagamenti effettuati con carta di credito.»

SparkRDD – Query1




```
public class ValQ1 implements Serializable {
    Double tip_amount;
    Double total_amount;
    Double tolls_amount;
    Long payment_type;
    Integer trips_number;
...
```

SparkRDD – Query1



```
// RDD:=[month, values aggr]
JavaPairRDD<String, ValQ1> reduced = filtered.reduceByKey((Function2<ValQ1, ValQ1, ValQ1>)
      (v1, v2) \rightarrow {}
           Double tips = v1.getTip amount() + v2.getTip amount();
           Double total = v1.getTotal_amount() + v2.getTotal_amount();
           Double tolls = v1.getTolls_amount() + v2.getTolls_amount();
            Integer trips = v1.getTrips number() + v2.getTrips number();
           ValQ1 v = new ValQ1();
           v.setTip amount(tips);
           v.setTotal amount(total);
           v.setTolls amount(tolls);
           v.setTrips number(trips);
            return v;
        });
// RDD:=[month,tip percentage,trips number]
JavaPairRDD<String, Tuple2<Double, Integer>> resultsRDD = reduced.mapToPair(
           Double tips = r._2().getTip_amount();
           Double tolls = r. 2().getTolls amount();
           Double total = r. 2().getTotal amount();
           Double mean = tips / (total - tolls);
           Integer trips = r. 2().getTrips number();
           return new Tuple2<>(r. 1(), new Tuple2<>(mean, trips));
       .sortByKey();
```

SparkRDD – Query1: Risultato Finale



 YYYY-MM	tip percentage	 trips number
2021-12	0.15973426958603487	 2361627
2022-01	0.15624681545577337	 1874779
2022-02	0.15672618046552844	2296156

Query 2

«Per ogni ora, calcolare la distribuzione in percentuale del numero di corse rispetto alle zone di partenza, la mancia media e la sua deviazione standard, il metodo di pagamento più diffuso»

SparkRDD – Query 2: Tuple


- Aggregazione su base oraria:
 - o tpep_pickup_datetime
- Distribuzione dei viaggi per ogni ora
 - PULocationID
- Media e deviazione standard delle mance.
 - tip_amount
- Metodo di pagamento preferito
 - o payment_type

```
public class ValQ2 implements Serializable {
    Double tips;
    Integer num_payments;
    Integer num_trips;
    Long payment_type;
    Double tips_stddev;
}
```


```
public class KeyQ2PU implements Serializable {
    String hour;
    Long source;
}
```

```
public class KeyQ2Pay implements Serializable {
    String hour;
    Long payment;
}
```


SparkRDD – Query2



SparkRDD – Query2




SparkRDD – Query2: Media Mance




```
// RDD:=[hour,statistics]
JavaPairRDD<String, ValQ2> trips = dataset.mapToPair(r ->
      new Tuple2<>(Tools.getHour(r.getTimestamp(0)),
                   new ValQ2(r.getDouble(6), r.getLong(4), 1, 1))); //tips,payment_type
JavaPairRDD<String, ValQ2> aggregated = trips.reduceByKey((Function2<ValQ2, ValQ2, ValQ2>) (v1, v2) -> {
            ValQ2 v = new ValQ2();
            Integer aggr = v1.getNum trips() + v2.getNum trips();
            Integer occ = v1.getNum_payments() + v2.getNum_payments();
            Double tips = v1.getTips() + v2.getTips();
           v.setNum_trips(aggr);
           v.setNum_payments(occ);
            v.setTips(tips);
            return v;
        });
JavaPairRDD<String, ValQ2> statistics = aggregated.mapToPair(
             Integer num_occurrences = r._2().getNum_payments();
             Double tips_mean = r._2().getTips() / num_occurrences;
             return new Tuple2<>(r._1(),
                    new ValQ2(tips_mean, num_occurrences));
      });
```

SparkRDD – Query2: Deviazione Standard




```
// RDD:=[hour,statistics deviation it]
JavaPairRDD<String, ValO2> iterations = joined.mapToPair( //joined = trips.join(statistics)
        r -> {
            Double tips_mean = r._2()._2().getTips();
            Double tip val = r. 2(). 1().getTips();
            Double tips dev = Math.pow((tip val - tips mean), 2);
            r. 2(). 2().setTips stddev(tips dev);
            return new Tuple2<>(r. 1(), r. 2(). 2());
       });
// RDD:=[hour,statistics deviation sum]
JavaPairRDD<String, ValQ2> stddev aggr = iterations.reduceByKey((Function2<ValQ2, ValQ2, ValQ2>) (v1, v2) -> {
   Double tips total stddev = v1.getTips stddev() + v2.getTips stddev();
   ValQ2 v = new ValQ2(v1.getTips(), v1.getNum payments(), v1.getPayment type(), tips total stddev);
    return v;
});
// RDD:=[hour,statistics deviation]
JavaPairRDD<String, ValQ2> deviation = stddev aggr.mapToPair(
            Double tips mean = r. 2().getTips();
            Integer n = r. 2().getNum payments();
            Double tips dev = Math.sqrt(r. 2().getTips stddev() / n);
            ValQ2 v = new ValQ2(tips mean, n, tips dev);
            return new Tuple2<>(r. 1(), v);
       });
```

SparkRDD – Query2: Metodo di Pagamento




```
// RDD:=[(hour,payment),1]
       JavaPairRDD<KeyQ2Pay, Integer> aggr pay = trips.mapToPair(r ->
                new Tuple2<>(
                        new KeyQ2Pay(r._1(),r._2().getPayment_type())
                        ,1));
       // RDD:=[(hour,payment),occurrences]
       JavaPairRDD<KeyQ2Pay, Integer> red pay = aggr pay.reduceByKey((Function2<Integer, Integer>)
(v1, v2) \rightarrow {}
            Integer occ = v1 + v2;
            return occ;
       });
       // RDD:=[hour,{((hour,payment),occurrences]
       JavaPairRDD<String, Iterable<Tuple2<KeyQ2Pay, Integer>>> grouped =
red pay.groupBy((Function<Tuple2<KeyQ2Pay, Integer>, String>) r -> r. 1().getHour());
       // RDD:=[hour,(top payment,occurrences)]
       JavaPairRDD<String, Long> top payments = grouped.mapToPair(r ->
                new Tuple2<>(
                        r. 1(),
                        getMostFrequentPayment(r._2())
                ));
```

SparkRDD – Query2: Distribuzione Zone



SparkRDD – Query2: Risultato Finale



```
// RDD:=[hour,payment stats,trips stats]
JavaPairRDD<String, Tuple2<Tuple2<ValQ2, Long>, Tuple2<Iterable<Tuple2<KeyQ2PU, Integer>>, ValQ2>>>
final joined = deviation
      .join(top_payments)
      .join(grouped zones)
      .sortByKey(new DateComparator());
// RDD:= [hour, List<percentages>, avgTip, devTip, topPayment]
JavaPairRDD<String, Tuple4<List<Tuple2<Double, Long>>, Double, Long>> results rdd = final joined
      .mapToPair(
             String hour = r._1();
             Long topPayment = r._2()._1()._2;
             double avgTip = r._2()._1()._1().getTips();
             double devTip = r._2()._1()._1().getTips_stddev();
             Integer totalTrips = r._2()._2()._2().getNum_trips();
             Iterable<Tuple2<KeyQ2PU, Integer>> occlist = r._2()._2()._1();
            List<Tuple2<Double, Long>> percentages = calcPercentagesList(occList, totalTrips);
             return new Tuple2<>(hour, new Tuple4<>(percentages, avgTip, devTip, topPayment));
      });
```

SparkRDD – Query2: Risultato Finale

												I
į	YYYY-MM-DD HH		perc_PU10	 perc_PU11	perc_PU12	perc_PU13	 perc_PU14 	 	avg_tip	stddev_tip	pref_payment	
ļ	2021-12-01-06		9,57854E+11	0	4,78927E+11	4,78927E+15	0	 	2,755987	3,542697	1	
	2021-12-01-07		7,02083E+11	0	2,34028E+11	6,08472E+15	0		2,493251	2,703577	1	
	2021-12-01-08		1,81061E+11	0	3,62122E+11	7,78562E+15	0		2,43526	2,445842	1	
	2021-12-01-09		1,67196E+12	0	1,67196E+12	4,84869E+15	0		2,495586	2,594521	1	

Query 3

«Per ogni giorno, identificare le 5 zone di destinazione (DOLocationID) più popolari (in ordine decrescente), indicando per ciascuna di esse il numero medio di passeggeri, la media e la deviazione standard della tariffa pagata (Fare amount). Nell'output della query, indicare il nome della zona (TLC Taxi Destination Zone) anziché il codice numerico.»


SparkRDD – Query 3: Tuple

- Identificazione delle cinque zone di destinazione più popolari
 - DOLocationID
- Aggregazione su base giornaliera
 - o tpep_dropoff_datetime
- Media e deviazione standard della tariffa pagata
 - fare_amount
- Media del numero di passeggeri
 - passenger_count


```
public class ValQ3 implements Serializable {
    Double passengers;
    Double fare;
    Integer occurrences;
    Double fare_stddev;
}
```

```
public class KeyQ3 implements Serializable {
    String day;
    Long dest;
}
```


SparkRDD – Query3



SparkRDD – Query3




SparkRDD – Query3: Medie




```
// RDD:=[(day,D0),statistics]
        JavaPairRDD<KeyQ3, ValQ3> days = dataset.mapToPair(
               r -> new Tuple2<>(new KeyQ3(Tools.getDay(r.getTimestamp(1)), r.getLong(3)),
                        new ValQ3(r.getDouble(9), r.getDouble(5), 1)));
       // RDD:=[(day,D0),statistics aggregated]
        JavaPairRDD<Key03, Val03> reduced = days.reduceByKey((Function2<Val03, Val03,</pre>
ValQ3>) (v1, v2) -> {
           Double pass = v1.getPassengers() + v2.getPassengers();
           Double fare = v1.getFare() + v2.getFare();
            Integer occ = v1.getOccurrences() + v2.getOccurrences();
           Val03 v = new Val03(pass, fare, occ);
           return v;
        });
        // RDD:=[(day,D0),statistics mean]
        JavaPairRDD<KeyQ3, ValQ3> mean = reduced.mapToPair(
                    Integer num_occurrences = r._2().getOccurrences();
                   Double pass_mean = r._2().getPassengers() / num_occurrences;
                   Double fare mean = r. 2().getFare() / num occurrences;
                   return new Tuple2<>(r._1(),
                            new ValQ3(pass mean, fare mean, num occurrences));
               });
```

SparkRDD – Query3: Deviazione Standard



SparkRDD – Query3: Grouping Statistiche



SparkRDD – Query3: Risultato Finale

										1
	YYYY-MM-DD	D01		avg pax DO1		avg fare DO1		stddev fare DO1		
	01/12/2021	Manhattan,Upper East Side North,Yellow Zone		1,36722E+16		1,00933E+16			 	
	02/12/2021	Manhattan,Upper East Side North,Yellow Zone		1,38101E+16		1,01709E+16		6,04909E+14	 	
	03/12/2021	Manhattan,Upper East Side North,Yellow Zone		1,39016E+16		9,90999E+15		1	 	
	04/12/2021	Manhattan,Upper East Side South,Yellow Zone		1,45702E+16		9,50914E+15		6,63641E+15		
										i.

SparkSQL – Dataset Creation

```
public Dataset<Row> createSchemaFromRDD(SparkSession spark, JavaRDD<Row> dataset) {
   List<StructField> fields = new ArrayList<>();
    fields.add(DataTypes.createStructField("tpep dropoff datatime", DataTypes.TimestampType, true));
    fields.add(DataTypes.createStructField("tip amount", DataTypes.DoubleType, true));
    fields.add(DataTypes.createStructField("tolls amount", DataTypes.DoubleType, true));
    fields.add(DataTypes.createStructField("total amount", DataTypes.DoubleType, true));
    fields.add(DataTypes.createStructField("payment_type", DataTypes.LongType, true));
   StructType schema = DataTypes.createStructType(fields);
   Calendar cal = Calendar.getInstance();
   cal.setTimeZone(TimeZone.getTimeZone("UTC"));
   SimpleDateFormat sdf = new SimpleDateFormat("yyyy-MM-dd hh:mm:ss");
   sdf.setTimeZone(TimeZone.getTimeZone("UTC"));
   JavaRDD<Row> rowRDD = dataset.map((Function<Row, Row>)
            v1 -> {
                Timestamp ts = v1.getTimestamp(1);
               cal.setTime(ts);
               Timestamp ts zone = Timestamp.valueOf(sdf.format(cal.getTime()));
               return RowFactory.create(ts zone, v1.getDouble(6), v1.getDouble(7), v1.getDouble(8), v1.getLong(4));
           });
   return spark.createDataFrame(rowRDD, schema);
```

SparkSQL – Query1

SparkSQL – Query2: Distribuzioni viaggi

```
Dataset<Row> data = createSchemaFromRDD(spark, dataset);
data.createOrReplaceTempView("trip infos");
// {timestamp, zone}, trips, total trip per hour, zone perc
Dataset<Row> scheduledTrips = spark.sql("SELECT timestamp, zone, trips, total trip hour, float(trips/total trip hour) as zone perc FROM " +
                "(SELECT date format(tpep pickup datatime, 'y-MM-dd HH') as timestamp, pu location id as zone, COUNT(*) as trips" +
                "FROM trip infos " +
                "GROUP BY timestamp, pu location id)" +
                "JOIN " +
                "(SELECT date format(tpep pickup datatime, 'y-MM-dd HH') as timestamp 2, COUNT(*) AS total trip hour" +
                " FROM trip infos GROUP BY timestamp 2)" +
               "ON timestamp = timestamp 2 ORDER BY timestamp ASC");
scheduledTrips.createOrReplaceTempView("scheduled trips");
// {timestamp}, list(zone id:zone perc)
Dataset<Row> groupedTrips = spark.sql("SELECT timestamp, collect list(concat ws(':', zone, zone perc)) as zone percs" +
               "FROM scheduled trips GROUP BY timestamp");
 groupedTrips.createOrReplaceTempView("grouped trips");
```

SparkSQL – Query2: Statistiche

```
// {timestamp}, trips, avg(tip), stddev(tip)
Dataset<Row> hourly_values = spark.sql("SELECT date_format(tpep_pickup_datatime, 'y-MM-dd HH') as timestamp, COUNT(*) as trips," +
               "avg(tip) AS avg_tip, stddev pop(tip) AS stddev tip " +
               "FROM trip_infos " +
                "GROUP BY timestamp " +
               "ORDER BY timestamp ASC");
hourly_values.createOrReplaceTempView("hourly values");
// {timestamp, payment type}, occurrences
Dataset<Row> paymentOccurrences = spark.sql("SELECT date format(tpep pickup datatime, 'y-MM-dd HH') AS timestamp," +
                "payment_type, COUNT(*) AS counted " +
                "FROM trip infos GROUP BY timestamp, payment type " +
               "ORDER BY timestamp ASC");
paymentOccurrences.createOrReplaceTempView("payment occurrences");
Dataset<Row> mostPopularPaymentType = spark.sql("SELECT timestamp, payment_type as most_popular_payment, counted AS payment_occurrences
                "FROM payment_occurrences table_1 WHERE counted =" +
                "(SELECT MAX(counted) FROM payment_occurrences WHERE timestamp = table_1.timestamp)
                "ORDER BY timestamp ASC");
mostPopularPaymentType.createOrReplaceTempView("most popular payment");
```

SparkSQL – Query2: Statistiche

SparkSQL – Query3: Top-5

SparkSQL – Query3: Output

Analisi performance


- Per l'analisi delle prestazioni sono state eseguite diverse ripetizioni delle Query
- Si valuta la media dei tempi di risposta di ogni ripetizione
- Si carica il dataset ogni volta che si esegue una query
- Specifiche macchina locale:

```
AMD Ryzen 5 5500U with Radeon Graphics, @6x2.10 GHz, RAM 8GB DDR4 @ 1593.9 MHz, Linux 5.15.23-76051523-generic amd64 (Pop!_OS by System76).
```

Analisi performance

 Nel grafico vediamo la valutazione delle query effettuate tramite RDD API rispetto a quelle eseguite dal modulo SparkSQL.

Q1	Q2	Q3	Q1SQL	Q2SQL	Q3SQL
11753	40248	25982	13612	33334	15308
11176	40915	26303	12299	33750	14053
11369	40195	26615	13157	32279	13524
11412	41048	25321	13470	34323	14088
11620	41589	25999	13442	31398	13362



Grafana Dashboard

- La dashboard è stata creata andando ad effettuare query sui file csv, risultati della computazione di Spark.
- Tramite un immagine docker di Grafana, viene offerta una visualizzazione dei dati tramite una semplice Dashboard.
- Link Dashboard : http://localhost:3001/d/QVfEthCnz/sabd-1?orgId=1


Grafana Dashboard – Query 1



Grafana Dashboard – Query 2



Grafana Dashboard – Query 3



Conclusioni

- Punti di forza:
 - Ragionevole velocità di esecuzione
 - Pre-processamento tramite framework esterno
- Limitazioni:
 - Supporto limitato di Grafana verso HDFS e MongoDB
 - Scalabilità limitata a causa delle ridotte risorse computazionali della singola macchina host

Grazie per l'attenzione

DANILO DELL'ORCO

JACOPO FABI

MICHELE SALVATORI